

Abordări statistice pentru sisteme de raționament incert

Un important țel al multor sisteme de rezolvare a problemelor este acela de a colecționa probe, pe măsură ce sistemul avansează și de a-și modifica comportamentul pe baza acestor dovezi. Statistica Bayesiană este o teorie statistică care poate modela acest tip de comportament.

Dacă notăm cu H evenimentul ca ipoteza (notată H) să fie adevărată, iar cu E evenimentul obținut prin observarea "dovezii" E , atunci conceptul fundamental al statisticii Bayesiene poate fi considerat ca fiind acela de *probabilitate condiționată*,

$$P(H|E),$$

reprezentând probabilitatea ca ipoteza H să fie adevărată, atunci când se observă dovada E .

Pentru a calcula această probabilitate trebuie luate în considerație probabilitatea prealabilă sau *a priori* a lui H (i.e. probabilitatea pe care am atribui-o lui H în lipsa oricăror probe), precum și gradul până la care E furnizează dovezi în favoarea lui H . Acest lucru se realizează prin definirea unui univers conținând o mulțime exhaustivă de ipoteze H_i , care se exclud reciproc și între care încercăm să discernem. Fie

E = dovezile obținute printr-un experiment E auxiliar.

$P(H_i)$ = probabilitatea a priori ca ipoteza H_i să fie adevărată.

$P(E|H_i)$ = probabilitatea de a observa dovezile E (probabilitatea să se realizeze E), atunci când ipoteza H_i este adevărată.

$P(H_i|E)$ = probabilitatea a posteriori ca ipoteza H_i să fie adevărată, fiind date dovezile E (știind că s-a realizat E).

Ca modalitate de calcul, probabilitatea a posteriori $P(H_i|E)$ se obține în mod Bayesian. Dacă notăm prin k numărul ipotezelor posibile, atunci formula lui Bayes, în varianta necondiționată, calculează această probabilitate a posteriori în felul următor (vezi Anexa 1):

$$P(H_i | E) = \frac{P(E | H_i) \times P(H_i)}{\sum_{n=1}^k P(E | H_n) \times P(H_n)}$$

Teorema lui Bayes poate sta la baza raționamentului incert. În general, probabilitatea $P(A|B)$ descrie probabilitatea condiționată a lui A atunci când singurele dovezi de care dispunem sunt reprezentate de B . Dacă însă există și alte dovezi relevante, atunci acestea trebuie și ele luate în considerație. Atunci când sunt date un corp prealabil de dovezi e și o nouă observație E , trebuie calculată probabilitatea condiționată a posteriori $P(H|E,e)$, prin aplicarea formulei lui Bayes în versiune

condiționată (vezi Anexa 1). Avem:

$$P(H | E, e) = P(H | E) \times \frac{P(e | E, H)}{P(e | E)}$$

Într-o lume arbitrar de complexă, dimensiunea mulțimii repartițiilor de probabilitate multidimensionale, care este necesară pentru a calcula această funcție, crește la valoarea 2^n dacă sunt luate în considerație n propoziții diferite. Utilizarea teoremei lui Bayes face ca problema să devină insolubilă din mai multe motive:

- Problema achiziționării de cunoștințe devine insurmontabilă, întrucât trebuie furnizate prea multe probabilități.
- Spațiul necesar pentru memorarea tuturor probabilităților este prea mare.
- Timpul necesar pentru calcularea tuturor probabilităților este prea mare.

În ciuda acestor neajunsuri, statistica Bayesiană constituie o bază atractivă pentru un sistem de raționament incert. Din această cauză, au fost dezvoltate câteva mecanisme care îi exploatează puterea, făcând, în același timp, problema rezolvabilă, din punct de vedere computațional. Două dintre aceste mecanisme constau în atașarea unor factori de certitudine regulilor de producție și respectiv în folosirea rețelelor Bayesiene.

Factori de certitudine și sisteme bazate pe reguli

Abordarea pe care o propunem aici provine de la sistemul MYCIN [Shortliffe, 1976; Buchanan și Shortliffe, 1984; Shortliffe și Buchanan, 1975], care își propune să recomande terapii adecvate pacienților cu infecții bacteriene. MYCIN este un exemplu de *sistem expert*, care interacționează cu medicul pentru a dobândi datele clinice de care are nevoie.

MYCIN reprezintă majoritatea cunoștințelor sale legate de diagnostic ca pe o mulțime de reguli, fiecare regulă având asociat un factor de certitudine. Sistemul folosește aceste reguli pentru a face un raționament de tip înlănțuire înapoi de la scopul său de a detecta organisme semnificative care pot cauza maladii și până la datele clinice disponibile. De îndată ce identifică asemenea organisme, MYCIN încearcă să selecteze o terapie prin care boala să fie tratată.

Pentru a înțelege cum exploatează sistemul informația incertă trebuie stabilit *cum combină acesta estimațiile de certitudine ale fiecărei reguli în parte pentru a produce o estimație finală a certitudinii concluziilor sale*. O întrebare naturală care se ridică având în vedere observațiile anterioare privind insolvabilitatea spre care conduce raționamentul Bayesian pur, este următoarea: ce compromisuri trebuie să facă tehnica MYCIN și care sunt riscurile asociate acestor compromisuri?

Un factor de certitudine (notat aici prin $FC[h,e]$ sau, mai simplu, prin FC) este definit în termenii a două componente:

- $MI[h,e]$ - o măsură (între 0 și 1) a încrederii în ipoteza h fiind dată dovada e . MI măsoară gradul până la care dovezile existente susțin ipoteza. Valoarea este 0 dacă aceste dovezi eșuează în susținerea ipotezei.
- $MN[h,e]$ - o măsură (între 0 și 1) a neîncrederii în ipoteza h fiind dată dovada e . MN măsoară gradul până la care dovezile existente susțin *negația ipotezei*. Valoarea este 0 dacă aceste dovezi susțin ipoteza.

Fiind date aceste două măsuri, putem defini factorul de certitudine ca fiind

$$FC[h,e] = MI[h,e] - MN[h,e]$$

Întrucât orice dovadă particulară fie susține, fie neagă o ipoteză și întrucât fiecare regulă MYCIN corespunde unei anumite dovezi (deși aceasta ar putea fi o dovadă compusă), este suficient un singur număr corespunzător fiecărei reguli pentru a defini atât MI , cât și MN și, prin urmare, factorul de certitudine, FC .

Factorii de certitudine ai regulilor MYCIN sunt furnizați de către experții care scriu aceste reguli. Pe măsură însă ce sistemul raționează, *acești factori de certitudine trebuie combinați*, pentru a reflecta dovezi multiple și reguli multiple aplicate aceleiași probleme. Cele trei tipuri de combinații care trebuie luate în considerație sunt reflectate în Fig. 5.1. În Fig. 5.1 (a) mai multe reguli furnizează dovezi referitoare la o singură ipoteză. În Fig. 5.1 (b) mai multe propoziții trebuie luate în considerație împreună pentru a ne forma o părere. În Fig. 5.1 (c) output-ul corespunzător unei reguli furnizează input pentru o alta.




Fig. 5.1

Înainte de a stabili formulele care trebuie folosite pentru a realiza aceste combinații, trebuie avute în vedere anumite *proprietăți pe care funcția de combinare trebuie să le satisfacă*, și anume:

- Întrucât ordinea în care dovezile sunt colectate este arbitrară, funcțiile de combinare trebuie să fie comutative și asociative.
- Până când este atinsă certitudinea, dovezile suplimentare ar trebui să crească valoarea lui MI . (În mod similar, dovezile care infirmă ipoteza ar trebui să crească valoarea lui MN).
- Dacă sunt înlănțuite inferențe incerte, atunci rezultatul ar trebui să fie mai puțin cert decât fiecare inferență în parte.

Acceptând necesitatea acestor proprietăți, vom considera mai întâi situația din Fig. 5.1 (a), în care mai multe probe se combină pentru a se determina factorul de certitudine al unei ipoteze. Măsura încrederii și a neîncrederii într-o ipoteză, fiind date două observații, s_1 și s_2 , se calculează după cum urmează:

$$MI[h, s_1 \wedge s_2] = \begin{cases} 0, & \text{dacă } MN[h, s_1 \wedge s_2] = 1 \\ MI[h, s_1] + MI[h, s_2] \times (1 - MI[h, s_1]), & \text{altfel} \end{cases}$$

$$MN[h, s_1 \wedge s_2] = \begin{cases} 0, & \text{dacă } MI[h, s_1 \wedge s_2] = 1 \\ MN[h, s_1] + MN[h, s_2] \times (1 - MN[h, s_1]), & \text{altfel} \end{cases}$$

$FC[h, s_1 \wedge s_2]$ se calculează pe baza lui $MI[h, s_1 \wedge s_2]$ și $MN[h, s_1 \wedge s_2]$. Se observă că, dacă se coroborează mai multe dovezi ale aceleiași ipoteze, atunci valoarea absolută a lui FC va crește. Dacă sunt introduse dovezi conflictuale, atunci valoarea absolută a lui FC va scădea.

În situația din Fig. 5.1 (b) este necesar *calculul factorului de certitudine al unei conjuncții de ipoteze*. FC se calculează pe baza valorilor MI și MN . Formulele folosite de MYCIN pentru calculul lui MI , corespunzător unei conjuncții și respectiv unei disjuncții de ipoteze, sunt următoarele:

$$MI[h_1 \wedge h_2, e] = \min(MI[h_1, e], MI[h_2, e])$$

$$MI[h_1 \vee h_2, e] = \max(MI[h_1, e], MI[h_2, e])$$

MN poate fi calculat în mod analog.

Fig. 5.1 (c) prezintă cazul în care *regulile sunt înlănțuite laolaltă*, ceea ce are ca rezultat faptul că ieșirea incertă a uneia dintre reguli trebuie să constituie intrarea alteia. Soluția dată acestei probleme se va ocupa și de cazul în care trebuie atribuită o măsură a incertitudinii intrărilor inițiale. Aceste situații sunt frecvente și corespund cazurilor în care dovezile provin ca urmare a unui experiment sau al

unui test de laborator ale cărui rezultate nu sunt suficient de exacte. În aceste cazuri, factorul de certitudine al unei ipoteze trebuie să ia în considerație atât tăria cu care probele sugerează ipoteza, cât și nivelul de încredere în aceste probe. MYCIN furnizează o regulă de înlănțuire care este definită după cum urmează.

Fie $MI'[h,s]$ măsura încrederii în h atunci când suntem absolut siguri de validitatea lui s . Fie e dovada care ne-a determinat să credem în s (spre exemplu, măsurătorile efectuate cu ajutorul instrumentelor de laborator sau rezultatele aplicării altor reguli). Atunci:

$$MI[h,s] = MI'[h,s] \cdot \max(0, FC[s,e])$$

Întrucât valorile FC inițiale din sistemul MYCIN sunt date de către experții care scriu regulile, nu este necesar să se formuleze o definiție mai exactă a factorului de certitudine decât cea dată până acum. Autorii sistemului inițial au dat însă o astfel de definiție, exprimând pe MI (care poate fi privit ca o descreștere proporțională a neîncrederii în h ca rezultat al observării lui e) după cum urmează:

$$MI[h,e] = \begin{cases} 1, & \text{daca } P(h) = 1 \\ \frac{\max[P(h|e), P(h)] - P(h)}{1 - P(h)}, & \text{altfel} \end{cases}$$

În mod similar, MN este descreșterea proporțională a încrederii în h ca rezultat al observării lui e :

$$MN[h,e] = \begin{cases} 1, & \text{daca } P(h) = 0 \\ \frac{\min[P(h|e), P(h)] - P(h)}{-P(h)}, & \text{altfel} \end{cases}$$

Aceste definiții s-au dovedit a fi incompatibile cu viziunea Bayesiană asupra probabilității condiționate. Modificări minore le fac însă compatibile [Heckerman, 1986]. În particular, putem redefini MI astfel:

$$MI[h,e] = \begin{cases} 1, & \text{daca } P(h) = 1 \\ \frac{\max[P(h|e), P(h)] - P(h)}{(1 - P(h)) \times P(h|e)}, & \text{altfel} \end{cases}$$

Definiția lui MN trebuie schimbată în mod similar.

Cu aceste reinterpretări nu mai există nici un conflict fundamental între tehnicile MYCIN și cele sugerate de statistica Bayesiană, MYCIN nefiind un sistem care conduce la insolubilitate.

Fiecare *FC* dintr-o regulă MYCIN reprezintă contribuția unei reguli individuale la încrederea pe care MYCIN o acordă unei anumite ipoteze. Într-un anumit sens, acest factor reprezintă o probabilitate condiționată, $P(H|E)$. Dar, într-un sistem Bayesian pur, $P(H|E)$ descrie probabilitatea condiționată a lui H atunci când singurele dovezi relevante sunt date de E . Dacă există și alte probe, atunci trebuie luate în considerare repartiții de probabilitate multidimensionale. Acesta este momentul în care MYCIN se distanțează de un sistem Bayesian pur, devenind mai eficient în execuție, dar cu riscul de a avea un comportament mai puțin intuitiv. În particular, *formulele MYCIN pentru cele trei situații din Fig. 5.1 fac presupunerea că toate regulile sunt independente*. Sarcina garantării independenței revine expertului care scrie regulile. Fiecare dintre scenariile combinate ale Fig. 5.1 devine vulnerabil atunci când această presupunere de independență este încălcată.

Abordarea care utilizează factori de certitudine și sisteme bazate pe reguli face *presupuneri puternice privitoare la independență*, datorită cărora este ușor de folosit în practică. În același timp, regulile trebuie scrise în așa fel încât ele să reflecte dependențele importante. Abordarea stă la baza multor programe, precum MYCIN, ca și a unei game largi de sisteme diferite, care au fost construite pe platforma EMYCIN [van Melle et al., 1981]. Platforma EMYCIN constituie o generalizare (numită *shell*) a lui MYCIN, în cadrul căreia au fost înlăturate toate regulile specifice domeniului. Unul dintre motivele pentru care acest cadru de lucru este util, în ciuda limitărilor sale, este acela că, într-un sistem robust, valorile exacte care sunt folosite nu au o importanță prea mare. Această abordare pare, de asemenea, a imita suficient de bine [Shultz et al., 1989] felul în care oamenii manipulează certitudinile.

Prezentăm implementarea în Prolog a unui sistem expert (SEPPCO) destinat asistării clienților unei firme de turism, în alegerea unei oferte pentru petrecerea concediului de odihnă, din totalitatea celor existente.

În cadrul acestui sistem, cunoștințele sunt reprezentate cu ajutorul regulilor de tip *if-then* (dacă-atunci), iar inferența utilizată este de tip *înlănțuire înapoi cu incertitudine* (în prezența incertitudinii). Incertitudinea este modelată prin intermediul factorilor de certitudine/ incertitudine de tip MYCIN. Considerăm că factorii de certitudine sunt cuprinși între -100 și 100; -100 corespunde valorii cu siguranță “fals”, iar 100 corespunde valorii cu siguranță “adevărat”. Se remarcă faptul că acești factori nu reprezintă probabilități.

Prezentăm, în continuare, baza de cunoștințe a sistemului SEPPCO. După cum se va vedea, conținutul bazei apare într-o formă foarte apropiată de cea a limbajului natural.

Baza de cunoștințe sistem SEPPCO

scopul este loc_concediu.

regula 1

daca buget_disponibil este redus
atunci in_romania fc 90.

regula 2

daca buget_disponibil este mediu
atunci in_romania fc 70.

regula 3

daca buget_disponibil este mare
atunci in_romania fc 50.

regula 4

daca departare este aproape
atunci in_romania.

regula 5

daca departare este departe
atunci in_romania fc 40.

regula 6

daca in_romania si
 la_mare si
 tip_oferta este sejur_1_luna si
 buget_disponibil este mare si
 anotimp este vara
atunci loc_concediu este neptun fc 80.

regula 7

daca in_romania si
 la_mare si
 tip_oferta este sejur_2_saptamani si
 buget_disponibil este mare si

anotimp este vara
atunci loc_concediu este mamaia fc 90.

regula 8

daca in_romania si
la_mare si
tip_oferta este sejur_2_saptamani si
anotimp este vara
atunci loc_concediu este costinesti fc 60.

regula 9

daca in_romania si
not la_mare si
tip_oferta este excursie si
anotimp este vara
atunci loc_concediu este manastiri_oltenia fc 70.

regula 10

daca in_romania si
not la_mare si
tip_oferta este excursie si
anotimp este vara
atunci loc_concediu este manastiri_moldova fc 60.

regula 11

daca not la_mare si
anotimp este vara
atunci loc_concediu este delta_dunarii.

regula 12

daca not la_mare si
tip_oferta este sejur_1_luna si
anotimp este vara
atunci loc_concediu_vara este busteni.

regula 13

daca la_mare si
departare este foarte_departe si
buget_disponibil este mare si
anotimp este vara
atunci loc_concediu_vara este bahamas fc 80.

regula 14

daca not la_mare si
departare este foarte_departe si
buget_disponibil este mare si
tip_oferta este excursie si
anotimp este vara
atunci loc_concediu este valea_loirei.

regula 15

daca departare este aproape si
not la_mare si
buget_disponibil este mediu si
anotimp este vara
atunci loc_concediu_vara este sinaia fc 70.

regula 16

daca la_mare si
buget_disponibil este mare si
anotimp este iarna
atunci loc_concediu este rio_de_janeiro.

regula 17

daca buget_disponibil este mare si
not la_mare si
departare este foarte_departe si
tip_oferta este excursie si
anotimp este iarna
atunci loc_concediu este austria_germania_franta fc 90.

regula 18

daca departare este foarte_departe si
not la_mare si
tip_oferta este sejur_2_saptamani si
buget_disponibil este mare si
anotimp este iarna
atunci loc_concediu este chamonix fc 60.

regula 19

daca departare este aproape si
not la_mare si
tip_oferta este sejur_2_saptamani si
buget_disponibil este mare si
anotimp este iarna
atunci loc_concediu este poiana_brasov.

regula 20

daca in_romania si
not la_mare si
tip_oferta este sejur_2_saptamani si
anotimp este iarna
atunci loc_concediu este busteni fc 70.

intreaba anotimp

optiuni (vara iarna)

afiseaza 'In ce anotimp preferati sa va petreceti concediul?'.

intreaba tip_oferta

optiuni (sejur_2_saptamani sejur_1_luna excursie)

afiseaza 'Preferati sa mergeti intr-o excursie, ori sa petreceti
un sejur intr-o statiune?'.

intreaba la_mare

optiuni (da nu)

afiseaza 'Preferati sa petreceti concediul la mare?'.

intreaba departare

optiuni (aproape departe foarte_departe)

afiseaza 'Preferati ca locul de petrecere a concediului sa fie
mai aproape, ori mai departe de localitatea unde locuiti?'.

intreaba buget_disponibil

optiuni (reduc mediu mare)

afiseaza 'Ce tip de buget alocati pentru petrecerea
concediului?'.

Din punctul de vedere al implementării în Prolog se poate spune că, în general, există două modalități de a lucra cu o bază de cunoștințe exprimată printr-un limbaj aproape natural. Prima dintre ele se bazează pe definirea unor operatori și aceasta este abordarea folosită în implementarea sistemului prezentat în capitolul 15 din [1]. Această abordare a fost folosită și de noi în descrierea făcută anterior. Cea de-a doua modalitate (exemplificată aici în implementarea sistemului SEPPCO) folosește, în esență, abilitatea Prolog-ului de a lucra cu gramatici de tip DCG ("definite clause grammar" – o extensie a gramaticilor independente de context). În această abordare, din punctul de vedere al programatorului, problema analizei sintactice (parsing) se reduce doar la specificarea unei gramatici DCG și, de aceea, am putea spune că această variantă oferă mai multă flexibilitate programatorului.